

تقرير اليوم السادس (Day 6)

التعلم العميق والشبكات العصبية الالتفافية (CNN)

التاريخ: 28 سبتمبر 2026

1. مقدمة وأهداف اليوم

انتقلنا في هذا اليوم من الرؤية الحاسوبية الكلاسيكية التي درسناها في اليوم الخامس (استخراج الخصائص، SVM، HOG، MLP) إلى التعلم العميق (Deep Learning)، حيث نتعلم الشبكة العصبية الالتفافية (CNN) من الصور بنفسها بدل استخراجها يدويًا. أهداف اليوم:

- فهم أساسيات الشبكة العصبية: neuron و weights و bias و activation و forward propagation و loss و backpropagation و gradient descent.
- بناء MLP على بيانات MNIST، ثم فهم معمارية Flatten ← Pooling ← ReLU ← CNN: Conv ← Dense.
- تطبيق CNN على مشروعين: Cats vs Dogs (تصنيف ثنائي) و CIFAR-10 (تصنيف متعدد الفئات).
- تحليل الأخطاء ومقارنة النماذج، وتجربة Data Augmentation و Transfer Learning.

المشروع	النوع	عدد الفئات	حجم الصورة	الهدف التعليمي
MNIST	متعدد الفئات	10	28×28 رمادي	فهم أساسيات CNN
Cats vs Dogs	ثنائي	2	RGB 128×128	تصنيف ثنائي على بيانات حقيقية
CIFAR-10	متعدد الفئات	10	RGB 32×32	تصنيف ملون أصعب

2. مفاهيم أساسية

معمارية CNN

تمر الصورة عبر طبقات Conv2D التي تستخرج الخصائص (حواف، أنسجة، أشكال) بواسطة فلاتر، ثم ReLU لإضافة اللاخطية، ثم MaxPooling لتصغير الأبعاد مع الاحتفاظ بالمعلومة المهمة، وأخيرًا Flatten و Dense لإنتاج التصنيف. مثال حساب الأبعاد لـ CIFAR-10 (بدون padding و stride = 1، والقانون: ناتج الالتفاف = الدخل - 3 + 1):

حجم الخرج	الطبقة
$3 \times 32 \times 32$	الدخل (Input)
$32 \times 30 \times 30$	Conv2D (32 فلتري)
$32 \times 15 \times 15$	MaxPooling
$64 \times 13 \times 13$	Conv2D (64 فلتري)
$64 \times 6 \times 6$	MaxPooling
$128 \times 4 \times 4$	Conv2D (128 فلتري)
$128 \times 2 \times 2$	MaxPooling
512	Flatten


اختيار الـ Loss وطبقة الخرج

- التصنيف الثنائي (Cats vs Dogs): طبقة sigmoid مع binary cross-entropy، وتعطي احتمال أن الصورة كلب.
- التصنيف متعدد الفئات (CIFAR-10): طبقة softmax من 10 وحدات مع sparse categorical cross-entropy، لأن التسميات أرقام صحيحة من 0 إلى 9.

3. المشروع الأول: Cats vs Dogs

استخدمنا صور RGB بحجم 128×128 من مجموعة تضم 12,500 صورة لكل فئة. أجريت ثلاث تجارب متتالية وحسنت النموذج في كل مرة:

التجربة	البيانات	Test Accuracy	ملاحظات
1. CNN بسيط	2000 صورة (1600 تدريب / 400 اختبار)	65.25%	Overfitting واضح: دقة التدريب 87.7% مقابل 69.4% للتحقق
2. نسخة محسنة	2000 صورة (400 / 320 / 1280)	71.25%	إضافة BatchNorm و GlobalAveragePooling و callbacks؛ AUC = 0.818
3. البيانات الكاملة	25,000 صورة (16,000 / 4,000 / 5,000)	79.98%	استكمال تدريب النموذج السابق 5 epochs؛ AUC = 0.891



الشكل 1: تحسن دقة الاختبار في تجارب Cats vs Dogs

تفاصيل التجربة الثالثة (الأفضل)

الفئة	Precision	Recall	F1-score	عدد الصور
Cat (قطعة)	0.8427	0.7372	0.7864	2500
Dog (كلب)	0.7664	0.8624	0.8116	2500

مصفوفة الالتباس (Confusion Matrix):

توقع: Dog	توقع: Cat	
657	1843	الحقيقة: Cat
2156	344	الحقيقة: Dog

التحليل: يميل النموذج قليلاً إلى توقع "كلب"؛ فقد صُنِّفت 657 قطعة على أنها كلاب مقابل 344 كلباً صُنِّفت قطعة. لذلك كان recall الكلاب (86%) أعلى من recall القطط (74%).

الاستنتاج: زيادة حجم البيانات وتحسين المعمارية رفعاً الدقة من 65% إلى 80%، وفُتِّلا الـ overfitting بشكل ملحوظ.

4. المشروع الثاني: CIFAR-10


مجموعة تضم 60,000 صورة ملونة بحجم 32×32 موزعة على 10 فئات: airplane و automobile و bird و cat و deer و dog و frog و horse و ship و truck. قُسمت البيانات إلى 45,000 للتدريب و 5,000 للتحقق و 10,000 للاختبار، مع تطبيع القيم بقسمتها على 255.

النموذج

ثلاث طبقات Conv (32 ثم 64 ثم 128 فلتراً) مع MaxPooling، ثم Dense(128) و Dropout(0.5) وطبقة softmax من 10 وحدات، بمجموع parameter 160,202.

النتائج

النموذج	Test Accuracy
Basic CNN (Notebook، 30 epochs المشروع)	71.73%
Basic CNN (Notebook، 15 epochs الاختبار)	70.46%
CNN + Data Augmentation (Notebook، 15 epochs المشروع)	61.87%
CNN + Data Augmentation (Notebook، 15 epochs الاختبار)	72.74%
Transfer Learning (MobileNetV2، 5 epochs)	85.96%



الشكل 2: مقارنة دقة الاختبار بين نماذج CIFAR-10

الملاحظات

- Overfitting في النموذج الأساسي:** بعد epoch 30 وصلت دقة التدريب إلى نحو 88% بينما بقيت دقة التحقق قرابة 71%، وارتفع validation loss من 0.82 إلى 1.19. أي أن النموذج يحفظ بدل أن يعمّم.
- Data Augmentation:** في تجربة Notebook المشروع انخفضت الدقة إلى 61.87% لأن النموذج لم يكتمل تدريبه بعد epoch 15 (كانت الدقة لا تزال في تحسن)، بينما أعطت في تجربة Notebook الاختبار 72.74% أي تحسناً بنحو 2.3 نقطة على النموذج الأساسي. يحتاج الـ augmentation إلى epochs أكثر ليظهر أثره.
- Transfer Learning:** وصل إلى 85.96% بتدريب parameter 12,810 فقط (طبقة التصنيف الجديدة) مع تجميد باقي شبكة MobileNetV2 المدربة مسبقاً على ImageNet، وهو أفضل أداء في اليوم كله.

4. تحليل الأخطاء: أخطأ النموذج الأساسي في 2,827 صورة من 10,000. راجعنا الصور الخاطئة ومصفوفة الالتباس لمعرفة الفئات المتشابهة التي يخلط بينها النموذج.

5. الدروس المستفادة

- البيانات أهم من تعقيد النموذج: مضاعفة حجم بيانات Cats vs Dogs أفادت أكثر من أي تعديل معماري.
- مراقبة الفجوة بين منحنيات التدريب والتحقق هي الطريقة الأساسية لاكتشاف الـ **overfitting**.
- الدقة وحدها لا تكفي: مصفوفة الالتباس و Precision/Recall تكشف انحياز النموذج نحو فئة معينة.
- أدوات مقاومة الـ **overfitting**: Data Augmentation و Dropout و BatchNorm و Early Stopping.
- **Transfer Learning** يعطي نتائج أفضل بكثير بتدريب أقل عندما تكون البيانات محدودة.

6. الملفات الناتجة

النوع	الملفات
Notebooks	CIFAR-10-Mini-Project.ipynb ، test-1.ipynb ، test-2.ipynb
النماذج المحفوظة	cifar10_cnn_model.keras ، cifar10_cnn_augmented_model.keras ، cats_dogs_cnn_model.keras ، dogs_cats_cnn_model.keras
نتائج التنبؤات (CSV)	cats_dogs_cnn_predictions.csv (دقة 54.25% ، تجربة أولية أضعف) ، dogs_cats_cnn_test_results.csv (دقة 65.25% ، تطابق التجربة 1)

7. الخطوات القادمة المقترحة

- تجربة Fine-tuning لطبقات من MobileNetV2 بعد Transfer Learning.
- إعادة اختبار Augmentation على CIFAR-10 بعدد epochs أكبر.
- تطبيق Augmentation و Transfer Learning على Cats vs Dogs لتجاوز 80%.